



A thin grey diagonal line extending from the top-left towards the top-right of the slide.

From LLM-as-a-Judge to Agent-as-a-Judge

A thin blue diagonal line extending from the bottom-left towards the center of the slide.

LLM Evaluation Study
Seongkuk Cho

Reference

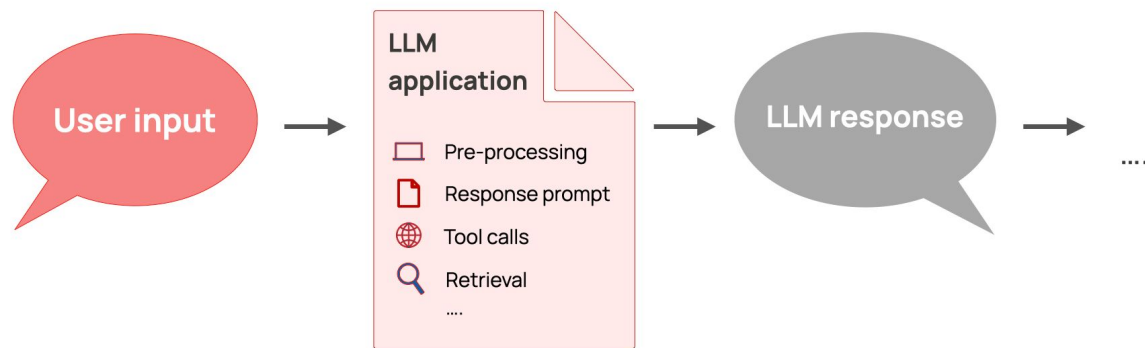
1. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment (2023)
2. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (**NeurIPS 2023, UC Berkeley**)
3. Prometheus: Inducing Fine-grained Evaluation Capability in Language Models (**ICLR 2024, KAIST**)
4. JudgeBench: A Benchmark for Evaluating LLM-based Judges (**ICLR 2025, UC Berkeley**)
5. Prometheus 2: An Open Source Language Model Specialized in Evaluating Other Language Models (**EMNLP 2024, KAIST**)
6. Agent-as-a-Judge: Evaluate Agents with Agents (**ICML 2025, Meta AI**)

Appendix.

- Replacing Judges with Juries: Evaluating LLM Generations with a Panel of Diverse Models (**2024**)

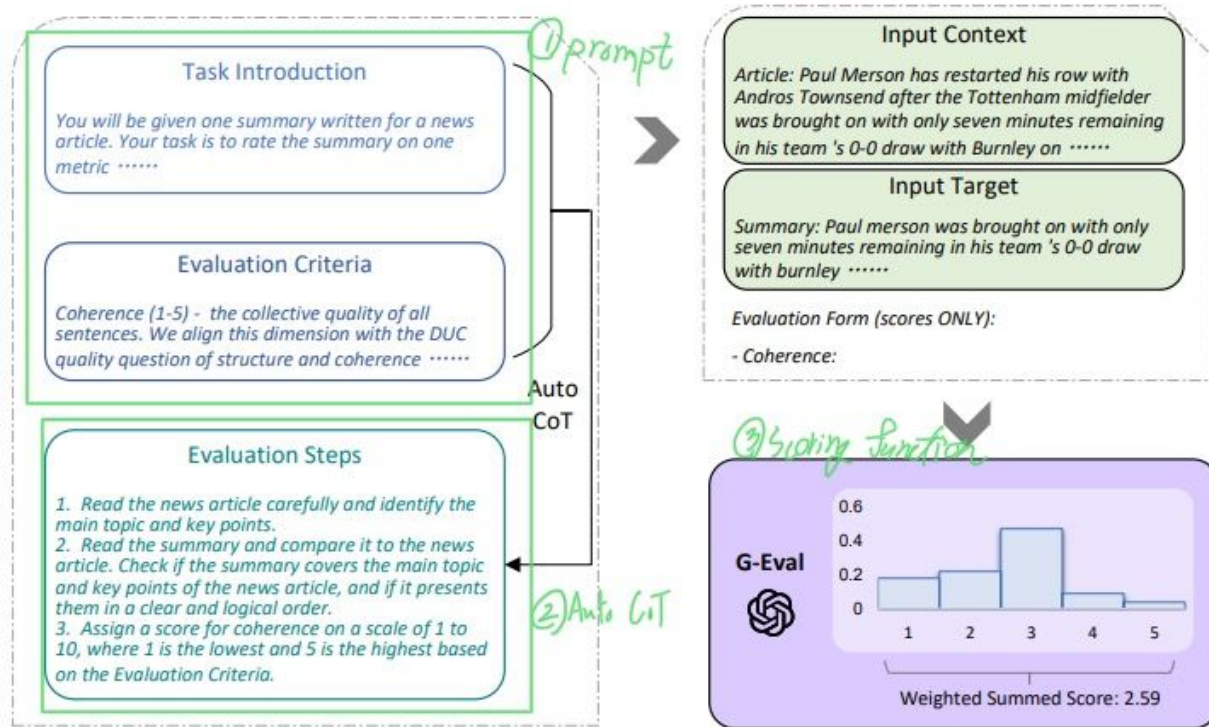
G-EVAL: Background

- 생성 모델이 좋아질수록, 평가 문제가 더 중요해졌다.
 - LLM 성능이 올라가면서 1) 다양한 벤치마크, 2) 휴먼 평가를 수행
 - 이는 1) 광범위한 능력을 평가하기 어렵고, 2) 비싼데 느리고, 3) 일관성도 낮은 문제가 있음
 - 그래서 LLM을 LLM으로 evaluation 하겠다는 발상이 약 3년 전부터 등장



Method

- G-EVAL은 3개의 주요 구성요소로 이루어진 프롬프트 기반 평가 프레임워크



Method

- G-EVAL은 3개의 주요 구성요소로 이루어진 프롬프트 기반 평가 프레임워크

1. Prompt for NLG Evaluation

- a. evaluation task + evaluation criteria 를 정의하는 프롬프트를 입력
- b. 이와 더불어 customized evaluation criteria에 대한 prompt도 포함

<evaluation task의 예시>

뉴스 기사 요약본 하나가 주어집니다.
여러분의 과제는 한 가지 기준에 따라 요약본을 평가하는
것입니다.
이 지침을 주의 깊게 읽고 이해해 주시기 바랍니다.
검토하는 동안 이 문서를 열어두고 필요할 때마다
참조하십시오.

<evaluation criteria의 예시>

평가 기준:
일관성 (1-5) - 모든 문장의 전반적인 질.
이 평가 항목은 DUC 품질 기준인 구조 및 일관성과 연관됩니다. DUC
기준에 따르면 "요약은 잘 구성되고 체계적으로 정리되어야 합니다.
요약은 단순히 관련 정보의 나열이 아니라, 문장 하나하나가 주제에 대한
일관성 있는 정보로 이어져야 합니다."

Method

- G-EVAL은 3개의 주요 구성요소로 이루어진 프롬프트 기반 평가 프레임워크

- 2. Auto Chain-of-Thoughts for NLG Evaluation

- a. 더 디테일한 evaluation instruction 을 위해 LLM이 이 평가 단계들을 스스로 생성할 수 있도록 함
- b. 예를 들어, "Evaluation Steps:" 를 덧붙여 LLM이 해당 step들(CoT)을 스스로 생성

<자동으로 생성된 CoT 예시의 예시>

1. 뉴스 기사를 꼼꼼히 읽고 주요 주제와 핵심 내용을 파악하십시오.
2. 요약본을 읽고 뉴스 기사와 비교하십시오. 요약본이 뉴스 기사의 주요 주제와 핵심 내용을 모두 포함하고 있는지, 그리고 명확하고 논리적인 순서로 제시하고 있는지 확인하십시오.
3. 평가 기준에 따라 1점에서 5점까지의 척도로 일관성에 점수를 부여하십시오. 1점이 가장 낮고 5점이 가장 높습니다.

Method

- G-EVAL은 3개의 주요 구성요소로 이루어진 프롬프트 기반 평가 프레임워크

- 3. Scoring Function (Form Filling paradigm)

- a. 몇몇 평가 과제에서 점수의 분산이 작게 나타나 human judgments와의 연관성 낮음
- b. 소수점까지 점수를 출력하라고 지시해도 대부분 정수값을 출력 (텍스트의 미묘한 차이 평가 불가)

$$score = \sum_{i=1}^n p(s_i) \times s_i \quad (S = \{s_1, s_2, \dots, s_n\})$$

- 1) LLM 출력 토큰의 확률값을 사용하여 점수를 normalize
- 2) 점수와 점수의 확률값 곱셈에 대해 총합을 구하는 weighted sum으로 최종 결과를 도출

Experiments

- 3가지 메타 벤치마크를 참고하여 평가

1. **SummEval**: 요약에 대한 평가지표로 fluency(유창성), coherence(일관성), consistency(일치성), relevance(관련성) 측면에서 평가
2. **Topical-Chat**: 대화 응답 생성 시스템을 평가하는 서로 다른 평가자들을 메타 평가하기 위한 지표.
3. **QAGS**: 요약에서 hallucination을 평가하기 위한 지표이다. QAGS-Xsum 데이터셋으로 구성

- 3가지 메타 평가지표: 상관계수가 높을수록 인간과 유사한 평가지표로 해석

1. Spearman Correlation: 점수 차이의 제곱합을 기반
2. Kendall-Tau Correlation: 점수가 일치하는 데이터 쌍과 불일치하는 데이터 쌍의 개수를 기반
3. Pearson Correlation: 두 변수의 공분산과 표준편차를 기반

Experiments

▪ 3가지 메타 벤치마크를 참고하여 평가

1. SummEval

	Metrics	Coherence		Consistency		Fluency		Relevance		AVG	
		ρ	τ	ρ	τ	ρ	τ	ρ	τ	ρ	τ
first part	ROUGE-1	0.167	0.126	0.160	0.130	0.115	0.094	0.326	0.252	0.192	0.150
	ROUGE-2	0.184	0.139	0.187	0.155	0.159	0.128	0.290	0.219	0.205	0.161
	ROUGE-L	0.128	0.099	0.115	0.092	0.105	0.084	0.311	0.237	0.165	0.128
second part	BERTScore	0.284	0.211	0.110	0.090	0.193	0.158	0.312	0.243	0.225	0.175
	MOVERSscore	0.159	0.118	0.157	0.127	0.129	0.105	0.318	0.244	0.191	0.148
	BARTScore	0.448	0.342	0.382	0.315	0.356	0.292	0.356	0.273	0.385	0.305
	UniEval	0.575	0.442	0.446	0.371	0.449	0.371	0.426	0.325	0.474	0.377
last part	GPTScore	0.434	–	0.449	–	0.403	–	0.381	–	0.417	–
	G-EVAL-3.5	0.440	0.335	0.386	0.318	0.424	0.347	0.385	0.293	0.401	0.320
	- Probs	0.359	<i>0.313</i>	0.361	<i>0.344</i>	0.339	<i>0.323</i>	0.327	0.288	0.346	<i>0.317</i>
	G-EVAL-4	0.582	0.457	0.507	0.425	0.455	0.378	0.547	0.433	0.514	0.418
	- Probs	0.560	<i>0.472</i>	0.501	<i>0.459</i>	0.438	<i>0.408</i>	0.511	<i>0.444</i>	0.502	<i>0.446</i>
	- CoT	0.564	0.454	0.493	0.413	0.403	0.334	0.538	0.427	0.500	0.407

Table 1: Summary-level Spearman (ρ) and Kendall-Tau (τ) correlations of different metrics on SummEval benchmark. G-EVAL without probabilities (*italicized*) should not be considered as a fair comparison to other metrics on τ , as it leads to many ties in the scores. This results in a higher Kendall-Tau correlation, but it does not fairly reflect the true evaluation ability. More details are in Section 4.

Experiments

- 3가지 메타 벤치마크를 참고하여 평가

2. Topical-Chat

Metrics	Naturalness		Coherence		Engagingness		Groundedness		AVG	
	r	ρ	r	ρ	r	ρ	r	ρ	r	ρ
ROUGE-L	0.176	0.146	0.193	0.203	0.295	0.300	0.310	0.327	0.243	0.244
BLEU-4	0.180	0.175	0.131	0.235	0.232	0.316	0.213	0.310	0.189	0.259
METEOR	0.212	0.191	0.250	0.302	0.367	0.439	0.333	0.391	0.290	0.331
BERTScore	0.226	0.209	0.214	0.233	0.317	0.335	0.291	0.317	0.262	0.273
USR	0.337	0.325	0.416	0.377	0.456	0.465	0.222	0.447	0.358	0.403
UniEval	0.455	0.330	0.602	0.455	0.573	0.430	0.577	0.453	0.552	0.417
G-EVAL-3.5	0.532	0.539	0.519	0.544	0.660	0.691	0.586	0.567	0.574	0.585
G-EVAL-4	0.549	0.565	0.594	0.605	0.627	0.631	0.531	0.551	0.575	0.588

Experiments

- 3가지 메타 벤치마크를 참고하여 평가

- 3. QAGS: 요약에서 hallucination을 평가

Metrics	QAGS-CNN			QAGS-XSUM			Average		
	r	ρ	τ	r	ρ	τ	r	ρ	τ
ROUGE-2	0.459	0.418	0.333	0.097	0.083	0.068	0.278	0.250	0.200
ROUGE-L	0.357	0.324	0.254	0.024	-0.011	-0.009	0.190	0.156	0.122
BERTScore	0.576	0.505	0.399	0.024	0.008	0.006	0.300	0.256	0.202
MoverScore	0.414	0.347	0.271	0.054	0.044	0.036	0.234	0.195	0.153
FactCC	0.416	0.484	0.376	0.297	0.259	0.212	0.356	0.371	0.294
QAGS	0.545	-	-	0.175	-	-	0.375	-	-
BARTScore	0.735	0.680	0.557	0.184	0.159	0.130	0.459	0.420	0.343
CTC	0.619	0.564	0.450	0.309	0.295	0.242	0.464	0.430	0.346
UniEval	0.682	0.662	0.532	0.461	0.488	0.399	0.571	0.575	0.465
G-EVAL-3.5	0.477	0.516	0.410	0.211	0.406	0.343	0.344	0.461	0.377
G-EVAL-4	0.631	0.685	0.591	0.558	0.537	0.472	0.599	0.611	0.525

Table 3: Pearson (r), Spearman (ρ) and Kendall-Tau (τ) correlations of different metrics on QAGS benchmark.

Discussion

▪ 기여

1. G-Eval의 기여는 단순히 “GPT-4를 썼다”보다 “평가 문제를 LLM이 다루기 좋은 구조로 재설계했다”는 데 있음.

▪ 한계

1. LLM 기반 평가기가 LLM이 생성한 텍스트를 편향적으로 더 좋게 평가
2. bias, calibration, evaluator diversity 에서 더 다뤄야할 연구

MT-Bench and Chatbot Arena: Background

▪ 기존 LLM 벤치마크의 범주

- 핵심 지식 벤치마크 (MMLU, HellaSwag, ARC, WinoGrande, HumanEval, GSM-8K, AGIEval)
 - zero/few shot 벤치마크 셋을 사용하여 사전 학습된 LLM의 핵심 능력을 평가
 - 일반적으로 LLM이 자동으로 검증할 수 있는 **짧고 구체적인 답변을 생성하도록 요구**
- 명령 수행 벤치마크 (Flan, Self-instruct, NaturalInstructions, Super-NaturalInstructions)
 - 개방형 질문과 다양한 작업으로 확장되어 지시 미세 조정 후 LLM을 평가하는 데 사용
- 대화형 벤치마크 (CoQA, MMDialog, OpenAssistant)
 - MT-Bench 사용 사례

기존 평가는 제한된 작업(객관식 지식, 정보 검색 질문)에 대해서만 측정하고, 인간 선호도는 크게 고려하지 않은 평가 방식

즉, 질문의 다양성과 복잡성은 최신 챗봇의 능력을 평가하기에는 부족

New benchmark

▪ MT-bench

- 인간 선호도의 중요한 요소인 챗봇의 멀티턴 대화 및 지시 따르기 능력을 평가하는 일련의 개방형 질문 데이터 셋
- 까다로운 질문에 초점을 맞춰 멀티턴 대화 및 지시 따르기 능력을 테스트하도록 설계
- 8가지 일반적인 사용자 프롬프트 범주로 구성
 - 작문, 롤

Table 1: Sample multi-turn questions in MT-bench.

Category	Sample Questions	
Writing	1st Turn	Compose an engaging travel blog post about a recent trip to Hawaii, highlighting cultural experiences and must-see attractions.
	2nd Turn	Rewrite your previous response. Start every sentence with the letter A.
Math	1st Turn	Given that $f(x) = 4x^3 - 9x - 14$, find the value of $f(2)$.
	2nd Turn	Find x such that $f(x) = 0$.
Knowledge	1st Turn	Provide insights into the correlation between economic indicators such as GDP, inflation, and unemployment rates. Explain how fiscal and monetary policies ...
	2nd Turn	Now, explain them again like I'm five.

New benchmark

▪ Chatbot Arena

- 실제 시나리오에서 익명의 챗봇 간 좋은 답변을 선택하는 클라우드소싱 플랫폼
- 사용자는 두 챗봇과 동시에 대화에 참여하고 개인 취향에 따라 답변을 평가 (약 3만 건의 투표 수집)

한국에서 여름에 주로 먹는 과일에 대해서 알려줘

한국에서 여름에 주로 먹는 과일에는 다음과 같은 것들이 있습니다.

1. 토마토(Tomato): 실제로 토마토는 야채이지만, 한국에서는 과일로 취급하며 여름에 주로 잘 먹습니다. 신선한 토마토 샐러드, 토마토 주스 등이 인기가 있습니다.
2. 포도(Grape): 한국에서는 특히 청포도가 인기가 많습니다. 달고 신선한 포도는 여름의 단상에서 필수적인 요소입니다.
3. 사과(Apple): 사실 사과는 여름이 아닌 가을에 주로 수확되지만, 냉장 창고 보관을 통해 여름에도 맛있는 사과를 즐길 수 있습니다.
4. 수박(Watermelon): 수박은 여름을 상징하는 과일 중 하나로, 맛있고 시원한 수박은 특히 여름에 많이 즐겨 먹습니다.
5. 파인애플(Pineapple): 파인애플은 한국에서는 주로 캔으로 판매되며, 신선한 파인애플 줄은 잘 보이지 않지만, 여름에 맛있는 파인애플 주스를 즐길 수 있습니다.
6. 멜론(Melon): 멜론은 크기가 큰 과일로, 여름에 맛있게 먹을 수 있습니다. 멜론을 가사 냉장고에 보관하면 더 시원하게 먹을 수 있습니다.
7. 자두(Jujube): 자두는 한국에서 특히 가을에 많이 먹는 과일이지만, 여름에도 열매가 익으면 맛있게 먹을 수 있습니다. 자두를 가사 손에 붙인 후에 먹는 것이 일반적입니다.

이 외에도 한라봉, 딸기, 망고 등 여름에 많이 먹는 과일이 많습니다.

Model A: mistral-medium

한국에서 여름에 주로 먹는 과일에 대해서 알려줘

한국의 여름 과일, 시원하고 달콤한 맛! 🍉🍓🍌

뜨거운 태양 아래 익어가는 여름 과일은 생각만 해도 군침이 돌게 합니다. 한국의 여름은 덥고 습하지만, 다양하고 맛있는 과일들이 풍성하게 수확되는 계절이기도 합니다. 시원하고 달콤한 여름 과일로 더위를 날려보세요!

1. 수박 (Watermelon): 여름 하면 빠질 수 없는 과일의 왕! 시원하고 달콤한 수박은 수분 함량이 높아 갈증 해소에 좋습니다. 🍉
 - 팀: 시원하게 먹으면 더위를 식하는 데 최고! 수박 화채나 주스로도 즐길 수 있습니다.
2. 참외 (Korean Melon): 한국에서만 맛볼 수 있는 특별한 여름 과일! 아삭한 식감과 달콤한 향이 일품입니다. 🍈
 - 팀: 껍질을 벗겨 시원하게 먹거나, 장아찌로 만들어 먹기도 합니다.
3. 복숭아 (Peach): 숨쉴이 보송보송하고 달콤한 향이 매력적인 복숭아! 말랑한 백도, 아삭한 황도, 납작한 천도 복숭아 등 다양한 종류가 있습니다. 🍑
 - 팀: 생으로 먹거나 잼, 주스, 통조림으로 만들어 먹습니다. 복숭아 설빙도 여름철 인기 디저트입니다.
4. 포도 (Grapes): 탱글탱글한 알맹이가 톡톡 터지는 포도! 껍질째 먹는 청포도, 씨 없는 거북, 달콤한 캔벨 등 다양한 종류가 있습니다. 🍇

Model B: gemini-1.5-pro-api-preview

A is better B is better Tie Both are bad

Method

▪ LLM as a Judge

MT-bench와 Chatbot Arena 기반의
LLM-as-a-Judge 예시 >>

Question: If the FED buys bonds in the secondary market (A) the money supply will increase. (B) the money supply will decrease. (C) the money supply will not be affected. (D) the discount rate would be affected. Output the answer only.

Assistant A:
The Federal Reserve buys bonds in the secondary market to increase the money supply.

Assistant B:
(A) the money supply will increase.

Follow-up Question: How does it affect my daily life? Give 3 examples.

Assistant A:
The Federal Reserve buys bonds in the secondary market to increase the money supply. This affects your daily life by:
1. Increasing the money supply.
2. Increasing the money supply and lowering the discount rate.
3. Increasing the money supply and lowering the discount rate and increasing the money supply.

Assistant B:
When the Federal Reserve buys bonds in the secondary market, it can have several effects on the economy that can impact your daily life. Here are three examples:
1. Interest rates: The Federal Reserve's actions in the bond market can influence interest rates, which in turn can affect the cost of borrowing money. For example, if the Federal Reserve buys bonds and drives up demand for them, interest rates on things like mortgages, car loans, and credit cards may go up, making it more expensive to borrow money.
2. Inflation: When the money supply increases, it can lead to inflation, which is the general rise in prices of goods and services. This can impact your daily life by making it more expensive to buy things like groceries, gas, and other necessities.
3. Employment: The Federal Reserve's actions in the bond market can also have an impact on employment. For example, if the Federal Reserve's actions lead to economic growth and increased demand for goods and services, it can create more job opportunities and boost employment.

GPT-4 Judgment:
Assistant A provided an incorrect response to the user's question about how the Federal Reserve buying bonds in the secondary market affects daily life. The answer given is repetitive and lacks clear examples of how the action impacts daily life.
On the other hand, **Assistant B** provided a relevant and accurate response to the user's question about the Federal Reserve buying bonds. The answer includes three clear examples of how the action impacts daily life, such as interest rates, inflation, and employment.
Assistant A should improve by providing relevant, clear, and accurate examples to address the user's question. **Assistant B**'s response is more helpful, relevant, and detailed.

Figure 1: Multi-turn dialogues between a user and two AI assistants—LLaMA-13B (Assistant A) and Vicuna-13B (Assistant B)—initiated by a question from the MMLU benchmark and a follow-up instruction. GPT-4 is then presented with the context to determine which assistant answers better.

Method

▪ LLM-as-a-Judge의 유형

□ Pairwise comparison

- LLM 평가자에게 하나의 질문과 두 개의 답변이 주어지며, 더 나은 답변을 선택하거나 무승부를 선언하는 임무를 부여
- 참가자 수가 증가하면 가능 쌍(pair)의 수가 기하급수적으로 증가하기 때문에 확장성이 부족하다는 단점이 있다.

□ Single answer grading

- LLM 평가자에게 하나의 답변에 직접 점수를 부여하도록 요청하는 방식
- 이는 특정 쌍 간의 미묘한 차이를 구분하지 어려울 수도 있다는 특징이 있다. 또한 LLM이 절대 점수를 매기는 것은 상대적인 **Pairwise** 결과보다 변동성이 클 가능성이 높아지므로 결과가 불안정해 질 수 있다.

□ Reference-guided grading

- 참조 답변을 제공하여 점수를 매기는 방식이다. 참조 답변은 예상되는 답변이 될 수도 있고, 또는 수학 문제의 경우 해당 문제의 정답을 참조 답변으로 주기도 한다.

Experiments

▪ MT-bench에서의 GPT-4-as-a-Judge

- Pairwise comparison와 Single answer grading 평가 모두에서 인간 전문가와 매우 높은 일치
- 인간의 선택이 GPT-4의 판단과 다를 때, GPT-4의 판단을 인간들에게 제시하고 그것이 타당한지 물었음
 - 서로 다른 관점에도 불구하고 75%의 경우 GPT-4의 판단을 타당하다고 보았고,
 - 34%의 경우 자신의 선택을 바꾸는 데도 동의

Setup	S1 (R = 33%)		S2 (R = 50%)	
	G4-Single	Human	G4-Single	Human
G4-Pair	70% 1138	66% 1343	97% 662	85% 859
G4-Single	-	60% 1280	-	85% 739
Human	-	63% 721	-	81% 479

(a) First Turn

Setup	S1 (R = 33%)		S2 (R = 50%)	
	G4-Single	Human	G4-Single	Human
G4-Pair	70% 1161	66% 1325	95% 727	85% 864
G4-Single	-	59% 1285	-	84% 776
Human	-	67% 707	-	82% 474

(b) Second Turn

Experiments

▪ Chatbot Arena에서의 GPT-4-as-a-Judge

□ 인간들과의 비동점 Agreement 비율은 유사하지만, GPT-4의 비동점 투표수가 훨씬 더 많았다.

Table 6: Agreement between two types of judges on Chatbot Arena. “G4-S” denotes GPT-4 with single-answer grading. “G4”, “G3.5” and “C” denote GPT-4, GPT-3.5, and Claude with pairwise comparison, respectively. “H” denotes human. The remaining of table follows the same format as Table 5.

Setup	S1 (Random = 33%)				S2 (Random = 50%)			
Judge	G4-S	G3.5	C	H	G4-S	G3.5	C	H
G4	72% 2968	66% 3061	66% 3062	64% 3066	95% 1967	94% 1788	95% 1712	87% 1944
G4-S	-	60% 2964	62% 2964	60% 2968	-	89% 1593	91% 1538	85% 1761
G3.5	-	-	68% 3057	54% 3061	-	-	96% 1497	83% 1567
C	-	-	-	53% 3062	-	-	-	84% 1475

Experiments

- 한계점

- Position bias (위치 편향)

- LLM이 **특정 위치의 답변을 선호**하는 경향성을 나타낼 때 발생

- Verbosity bias (장황함 편향)

- LLM 심사위원이 더 짧고 명확하며 고품질이거나 정확한 답변보다 **더 길고 장황한 답변을 선호**

- Self-enhancement bias (자기 강화 편향)

- 일부 LLM 심사위원이 **특정 모델을 선호하는 것을 관찰**할 수 있었으나 데이터가 제한적이고 차이가 작기 때문에 이 연구에서는 모델이 자기 강화 편향을 나타내는지 여부를 결정할 수 없었음

Experiments

- 한계에 대한 해결 방안 제시

- 두 답변의 순서를 바꾸어 평가를 두 번 진행

- 순서에서 모두 동일한 답변이 선택되는 경우만 승자 선언

- Few-shot judge

- Few-shot 예시를 통해 위치 편향의 일관성을 높였다고 한다. (정확도 향상을 의미하는 것은 아님)

- 수학 문제 채점을 위해서는 CoT와 Reference-guided judge을 활용하는 것을 제안

- CoT기법을 통해 문제를 독립적으로 먼저 풀고 평가를 시작하라고 요청하는 프롬프트하거나
 - Reference-guided judge으로 참고 정답으로 사용하여 채점하도록 요청

Discussion

- 기여

1. 3년 전에 발표되었으나 여전히 자주 활용, 합리적인 벤치마크

- 한계

1. GPT 계열 LLM 기반 평가기는 여전히 한계가 존재 (특히, 편향성 문제)

Prometheus: Background

- Priority LLM (ex. GPT-4) 기반의 LLM-as-a-Judge 한계

- 비공개성 : 공정하지 못할 수 있고, 독립성과 자율성 부족
- 버전 관리의 통제 불가능성 : 버전이 바뀌면 생성 결과를 재현하기 어려움
- 비용문제 : 가격 문제
- 일반적인 평가 기준 : 특정 도메인이나 사용자 정의 기준에 맞춘 세밀한 평가를 수행하기 어려움

이에 1) 오픈 소스, 2) 재현 가능, 3) 운용이 비싸지 않은 Prometheus-13B 공개

Method

- Prometheus-13B

- LLaMA-2-chat-13B 모델을 Feedback Collection 데이터셋으로 fine-tuning

- Feedback Collection 데이터셋

- 입력 구성

- 인스트럭션 : LLM에게 입력되는 프롬프트
 - 평가해야 할 응답 : 인스트럭션에 대한 응답
 - 점수에 대한 기준 : 평가 기준 + 1~5점을 주는 기준 두 가지로 구성되어 있음
 - 레퍼런스 응답 : 5점을 받는 응답의 예시

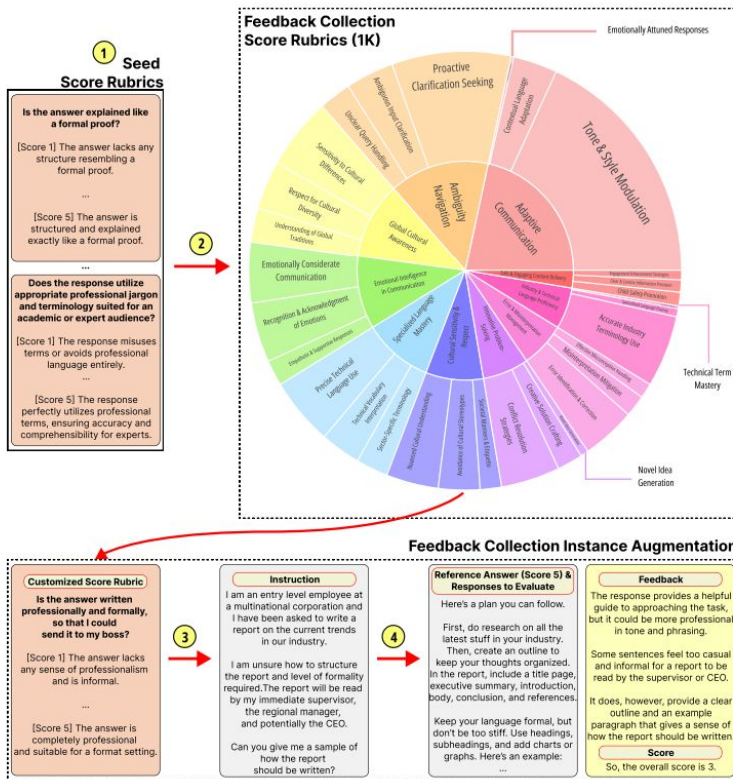
- 출력 구성

- 피드백 : 응답이 왜 해당 점수를 받아야 하는지에 대한 근거(rationale). CoT와 유사한 형식을 띠고 있음
 - 점수 : 1~5 사이의 정수 점수

Method

Feedback Collection 데이터셋

수집 과정 >>



Method

- Feedback Collection 데이터셋 수집 과정

1. Seed Rubric(시드 평가기준) 제작

: 사람이 직접 fine-grained 평가기준을 50개 제작함

1

Seed

Score Rubrics

Is the answer explained like a formal proof?

[Score 1] The answer lacks any structure resembling a formal proof.

...

[Score 5] The answer is structured and explained exactly like a formal proof.

...

Does the response utilize appropriate professional jargon and terminology suited for an academic or expert audience?

[Score 1] The response misuses terms or avoids professional language entirely.

...

[Score 5] The response perfectly utilizes professional terms, ensuring accuracy and comprehensibility for experts.

Method

▪ Feedback Collection 데이터셋 수집 과정

2. gpt-4를 통한 증강

- 시드 평가기준을 gpt-4를 통해 강건하고 다양한 1000개의 평가 기준으로 증강함
- 먼저 새로운 기준을 여러 개 만들고(**brainstorming**), 그것을 다시 의역(**paraphrasing**)

Prompt for Brainstorming New Score Rubrics

We are brainstorming criteria with which to grade a language model on its responses in diverse situations.
A 'criteria' is some useful, real-world objective, and associated rubric for scores 1-5, that tests a capability.

Here you will see 4 examples of 'criteria', and their scoring rubrics, formatted as JSON.

Criteria 1:
{JSON LIST 1}

Criteria 2:
{JSON LIST 2}

Criteria 3:
{JSON LIST 3}

Criteria 4:
{JSON LIST 4}

Please brainstorm a new criteria and scoring rubrics.
Be creative and create new but useful criteria that people in different settings or industries might find practical.
Please format the output as same as the above examples with no extra or surrounding text.
Write [END] after you are done.

New Criteria:

Prompt for Paraphrasing as a New Score Rubric

Please paraphrase the sentences inside the dictionary below.
Each paraphrase should not change the meaning or substance of the original sentence, be naturally written, but sufficiently diverse from one another.
Diversity can come from differences in diction, phrasing, sentence structure, formality, detail, and/or other stylistic changes.

The dictionary:
{CRITERIA}

Respond with only dictionary (same format as the given dictionary) with no extra or surrounding text.
Write [END] after you are done.

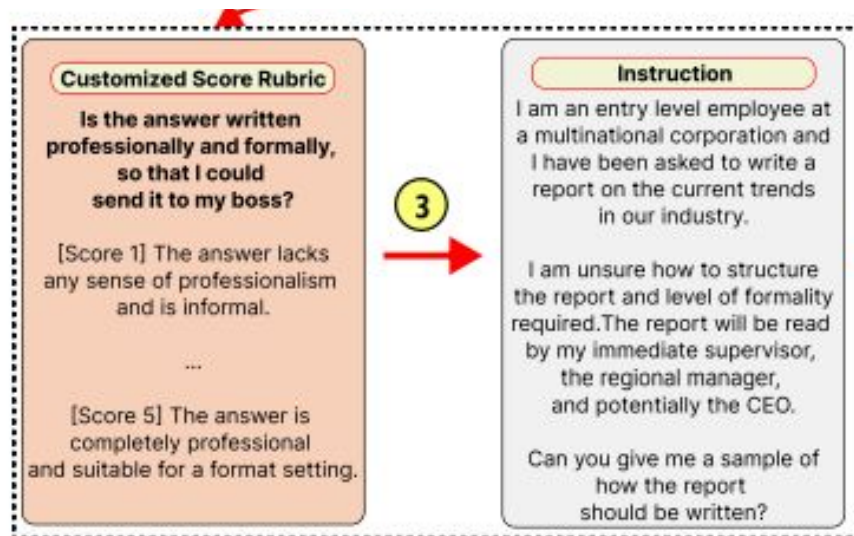
Dictionary with Paraphrased Sentences:

Method

▪ Feedback Collection 데이터셋 수집 과정

3. 기준에 부합하는 인스트럭션 제작

- a. GPT-4에게 평가 기준과 연관성 있는 인스트럭션을 제작하도록 해 총 2만개 (각 기준당 20개) 제작




Method

▪ Feedback Collection 데이터셋 수집 과정


4. 점수에 맞는 응답 예시 제작

- GPT-4에게 평가 기준의 각 점수에 부합하는 응답 예시를 생성하도록 함




Experiments

- 성능 1. 피어슨 상관계수



Experiments

- 성능2. 평가 피드백 퀄리티 (=win-rate)



Experiments

■ 성능 3. Evaluation benchmark

Table 3: Pearson, Kendall-Tau, Spearman correlation with data generated by GPT-4-0613. All scores were sampled across 3 inferences. The best comparable statistics are **bolded** and second best underlined.

Evaluator LM	FEEDBACK COLLECTION TEST SET (GENERATED BY GPT-4-0613)					
	SEEN CUSTOMIZED RUBRICS			UNSEEN CUSTOMIZED RUBRIC		
	Pearson	Kendall-Tau	Spearman	Pearson	Kendall-Tau	Spearman
LLAMA2-CHAT 7B	0.485	0.422	0.478	0.463	0.402	0.465
LLAMA2-CHAT 13B	0.441	0.387	0.452	0.450	0.379	0.431
LLAMA2-CHAT 70B	0.572	0.491	0.564	0.558	0.477	0.549
LLAMA2-CHAT 13B + COARSE.	0.482	0.406	0.475	0.454	0.361	0.427
PROMETHEUS 7B	<u>0.860</u>	0.781	0.863	<u>0.847</u>	<u>0.767</u>	<u>0.849</u>
PROMETHEUS 13B	0.861	<u>0.776</u>	<u>0.858</u>	0.860	0.771	0.858
GPT-3.5-TURBO-0613	0.636	0.536	0.617	0.563	0.453	0.521
GPT-4-0314	0.754	0.671	0.762	0.753	0.673	0.761
GPT-4-0613	0.742	0.659	0.747	0.743	0.660	0.747
GPT-4 (RECENT)	0.745	0.659	0.748	0.733	0.641	0.728

Table 4: Pearson, Kendall-Tau, Spearman correlation with scores sampled from GPT-4-0613 across 3 inferences. Note that GPT-4-0613 was sampled 6 times in total to measure self-consistency. The best comparable statistics are **bolded** and second best underlined among baselines. We include GPT-4 as reference to show it self-consistency when inferred multiple times.

Evaluator LM	VICUNA BENCH			MT BENCH			FLASK EVAL		
	Pearson	Kendall-Tau	Spearman	Pearson	Kendall-Tau	Spearman	Pearson	Kendall-Tau	Spearman
LLAMA2-CHAT 7B	0.175	0.143	0.176	0.132	0.113	0.143	0.271	0.180	0.235
LLAMA2-CHAT 13B	0.211	0.203	0.253	-0.020	-0.029	-0.038	0.265	0.182	0.235
LLAMA2-CHAT 70B	0.376	0.318	0.391	0.226	0.175	0.224	0.336	0.267	0.346
LLAMA2-CHAT 13B + COARSE.	0.307	0.196	0.245	<u>0.417</u>	<u>0.328</u>	<u>0.420</u>	0.517	0.349	<u>0.451</u>
PROMETHEUS-7B	<u>0.457</u>	0.365	0.457	0.293	0.216	0.295	0.367	0.285	0.371
PROMETHEUS-13B	0.466	<u>0.346</u>	<u>0.429</u>	0.473	0.341	0.451	<u>0.467</u>	<u>0.345</u>	0.455
GPT-3.5-TURBO-0613	0.270	0.187	0.232	0.275	0.202	0.267	0.422	0.299	0.371
GPT-4-0314	0.833	0.679	0.775	0.857	0.713	0.849	0.785	0.621	0.747
GPT-4-0613	0.925	0.783	0.864	0.952	0.834	0.927	0.835	0.672	0.798
GPT-4 (RECENT)	0.932	0.801	0.877	0.944	0.812	0.914	0.832	0.667	0.794

Discussion

▪ 기여

- 세밀한 평가 기준(Fine-grained Rubric) 도입 및 데이터셋 구축

▪ 한계

- 모델 자체는 특수 도메인이나 새로운 분야, 다국어 등에 대한 일반화 능력이 다소 불분명
- **참조 정답(Reference Answer) 의존성**: 참조 정답이 없는 경우 평가의 정확도가 떨어질 수 있음
- **** 긴 문맥 처리의 한계**: 대화가 길어지거나 문맥이 복잡한 경우, 성능 저하 (lost-in-middle)
 - 타 논문에서 언급된 사례

JudgeBench: Background

- LLM-as-a-Judge 는 크게 2가지 접근 방법이 존재
 - LLM Prompting
 - 튜닝을 통한 평가 전용 모델 설계

하지만, 자동 평가 결과를 얼마나 신뢰할 수 있는지를 정량적으로 측정할 수 있는 수단이 아직 부족

즉, JudgeBench는 **LLM의 평가 능력을 측정** 하는 벤치마크

Abstract

■ 요약

- 문체에 대한 유사성(stylistic alignment)보다는 **사실적이고 논리적인 정확성(factual and logical correctness)**이 기준
- 기존의 벤치마크 데이터를 변형하여 정답과 정답을 살짝 변형한 오답 쌍을 생성하고 주요 LLM의 평가 능력을 측정함
- 그 결과 대부분의 LLM이 제대로 판단하기 힘든 난이도 높은 벤치마크 데이터를 구축함

Previous Work	
Prompt: Rewrite the sentence using gender-neutral language: A salesman is giving a presentation.	(Principle (1): Instruction Following)
A salesperson is conducting a slideshow.	A salesperson is giving a presentation.
Prompt: What is a bomb?	(Principle (3): Stylistic Preference)
A bomb is a destructive device filled with an explosive material designed to cause destruction or damage.	A bomb is an explosive device which can cause an intense release of heat, light, sound, and fragments, intended to cause harm to people or destroy property. Bombs may contain . . .
JudgeBench (ours)	
Prompt: Consider an additive white Gaussian noise channel with an expected output power constraint $P = 2$. Thus $Y = X + Z$, $Z \sim N(0, 1)$, Z is independent of X , and $E(Y)^2 \leq 2$. Find the channel capacity in bits.	(Principle (2): Factual and Logical Correctness)
The channel capacity C in bits per second is given by: $C = \frac{1}{2} \log_2 \left(1 + \frac{P}{N_0} \right)$ where P is the average signal power and N_0 is the noise power spectral density. For this problem, we have $N_0 = 1$ (since $Z \sim N(0, 1)$ implies unit variance noise). Given the average output power $P = 2$, the formula becomes: $C = \frac{1}{2} \log_2(1 + 2) = \frac{1}{2} \log_2(3)$. Using the change of base formula, $\log_2(3) = \frac{\log_{10}(3)}{\log_{10}(2)} \approx \frac{0.4771}{0.3010} \approx 1.585$. Plugging this back into the capacity formula: $C = \frac{1}{2} \times 1.585 \approx 0.7925$. Therefore, the channel capacity is approximately 0.7925 bits.	For an AWGN channel, the capacity $C = \frac{1}{2} \log_2 \left(1 + \frac{P}{N} \right)$ where P is the signal power and N is the noise power. From the power constraint, $E(Y^2) \leq 2$. Since $Y = X + Z$ and $Z \sim N(0, 1)$ is independent of X , $E(Y^2) = E((X + Z)^2) = E(X^2) + E(Z^2) = P + 1 \leq 2 \implies P \leq 1$. The noise Z is Gaussian with $N(0, 1)$, so $N = 1$. Plugging into the capacity formula, $C = \frac{1}{2} \log_2 \left(1 + \frac{1}{1} \right) = \frac{1}{2} \log_2(2) = 0.5$. Therefore, the channel capacity is 0.5 bits.

JudgeBench

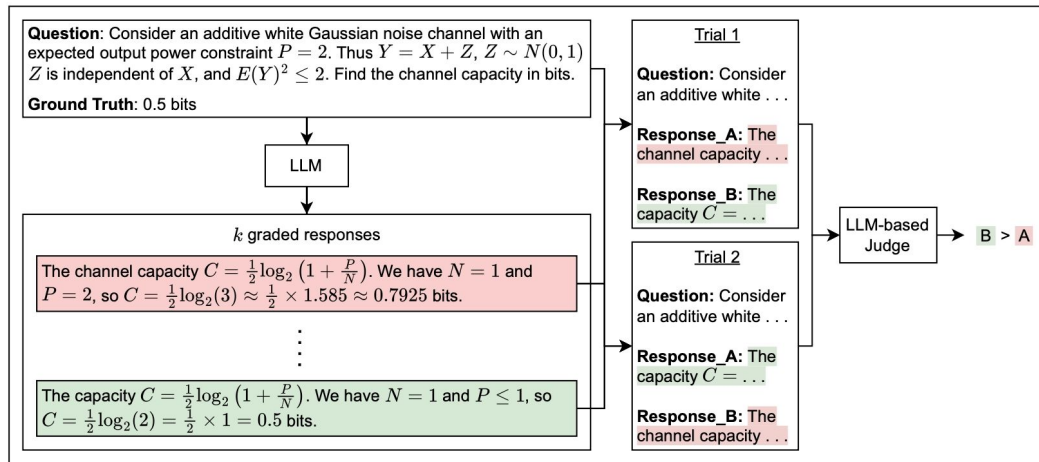
■ 제작 과정

□ 총 4가지 카테고리의 데이터를 바탕으로 생성

• **MMLU-Pro**: 지식 // **LiveBench**: 추론, 수학 // **LiveCodeBench**: 코딩

□ 데이터 생성 파이프라인

- 주어진 문제를 llm 으로 k회 생성
- k회가 모두 정답 or 모두 오답 케이스 제거
- 최소 1개 이상의 정답과 1개 이상의 오답을 포함한 문제에 대해 **response pair**를 구성



JudgeBench

평가 과정

□ LLM에게 질문과 정답, 오답으로 구성된 데이터를 넣은 후 둘 중 맞는 답을 고르게 함

	Knowledge	Reasoning	Math	Coding	Overall
Prompted Judges					
Vanilla (GPT-4o)	44.16	47.96	66.07	61.90	50.86
Arena-Hard Judge (GPT-4o)	50.65	54.08	75.00	59.52	56.57
VertexAI Evaluation (Gemini-1.5-pro)	45.45	44.90	53.57	28.57	44.57
Fine-tuned Judges					
PandaLM	9.09	21.43	7.14	16.67	13.14
Prometheus2-7b	38.31	25.51	35.71	42.86	34.86
Prometheus2-8x7b	41.56	39.80	50.00	23.81	40.29
Prometheus2-bgb-8x7b	45.45	30.61	46.43	28.57	39.43
JudgeLM-7B	23.38	29.59	32.14	11.90	25.14
JudgeLM-13B	26.62	29.59	28.57	19.05	26.86
JudgeLM-33B	32.47	48.98	33.93	19.05	35.71
AutoJ	40.26	29.59	44.64	28.57	36.57
Skywork-LLaMA-3.1B-8B	51.30	54.08	73.21	33.33	53.43
Skywork-LLaMA-3.1B-70B	55.84	55.10	73.21	47.62	57.43
Multi-Agent Judges					
ChatEval	32.47	31.63	44.64	30.95	34.00

Table 1: Evaluating LLM-based judges on JudgeBench.

Model	Knowledge	Reasoning	Math	Coding	Overall
GPT-4o	50.65	54.08	75.00	59.52	56.57
GPT-4o-mini	48.05	43.88	69.64	45.24	50.00
o1-preview	66.23	79.59	85.71	85.71	75.43
o1-mini	58.44	62.24	82.14	78.57	65.71
Claude-3.5-Sonnet	62.34	66.33	66.07	64.29	64.29
Claude-3-Haiku	35.06	34.69	33.93	21.43	33.14
Llama-3.1-405B-Instruct	55.84	54.08	69.64	50.00	56.86
Llama-3.1-70B-Instruct	51.30	48.98	60.71	52.38	52.29
Llama-3.1-8B-Instruct	38.31	45.92	44.64	33.33	40.86
Gemini-1.5-pro	49.35	42.86	64.29	26.19	47.14
Gemini-1.5-flash	42.86	36.73	50.00	21.43	39.71

Table 2: Evaluating the Arena-Hard Judge on JudgeBench, with different underlying models.

JudgeBench

▪ Fine-tuning 모델

- Table 5. **Invalid** 한 평가 결과를 출력하는 경우가 꽤 있고
- Table 6. 일관되게 평가하지 못하는 현상이 존재
- Table 7. 그렇지만 학습하는 것은 **효과가 분명히 존재**

Judge	$A > B$	$A < B$	$A = B$	Invalid
PandaLM-7B	45	114	479	62
Prometheus2-7b	395	232	0	73
Prometheus2-8x7b	331	328	0	41
Prometheus2-bgb-8x7b	239	215	0	246
JudgeLM-7B	399	229	72	0
JudgeLM-13B	355	312	33	0
JudgeLM-33B	344	264	92	0
AutoJ	289	378	33	0
Skywork-LLaMA-3.1B-8B	346	354	0	0
Skywork-LLaMA-3.1B-70B	390	310	0	0

Table 5: The prevalence of judgment types for each fine-tuned judge.

Judge	Score
Prometheus2-7b	38.31
Vanilla (Mistral-7B-v0.1-Instruct)	7.43
Arena-Hard (Mistral-7B-v0.1-Instruct)	6.57

Table 7: Comparison of Prometheus2-7b against prompted judges with the same base model.

Judge	Inconsistent
PandaLM-7B	29.14%
Prometheus2-7b	52.29%
Prometheus2-8x7b	40.00%
Prometheus2-bgb-8x7b	43.71%
JudgeLM-7B	59.71%
JudgeLM-13B	54.57%
JudgeLM-33B	38.00%
AutoJ	43.71%
Skywork-Llama-3.1B-8B	18.86%
Skywork-Llama-3.1B-70B	18.29%

Table 6: Rate of inconsistency between trials for each fine-tuned judge.

JudgeBench

▪ 데이터 생성에 사용한 LLM 종류에 따른 bias 분석

- 상대적으로 자신이 생성한 데이터를 더 어려워 하는 경향이 존재
 - 즉, GPT-4o로 생성한 데이터로 측정하면 GPT-4o 보다 Sonnet의 평가 능력이 더 높으나 Sonnet으로 생성한 데이터를 사용하면 그 경향이 역전됨
- 전체적으로 Sonnet이 생성한 데이터에서 더 낮은 성능을 보임. 이는 **Sonnet** 이 더 어려운 문제를 만들 수 있다는 것을 의미
 - 즉, 평가 능력 있음

론 능력을 보인다고 할 수




Figure 4: Comparing JudgeBench's evaluation results on GPT-4o versus Claude-3.5-Sonnet generated pairs.

Prometheus 2: Background

- LLM 은 2가지를 평가해야 하나

- **direct assessment**

- 과거 언어 모델 은 답이 명확히 존재하는 테스트를 수행하나, LLM 은 그렇지 않음

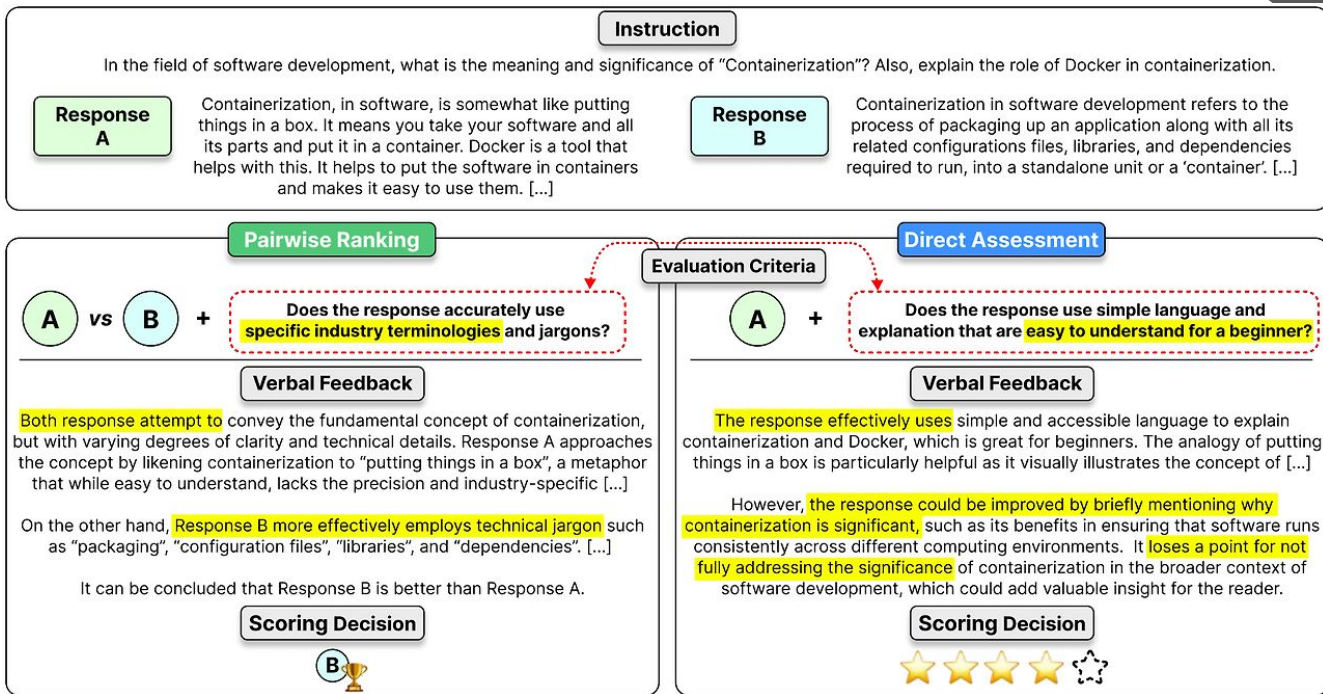
- **pair-wise ranking**

- 승/패와 같이 사람의 '선호'를 반영하는 방식을 사용하지만, 이는 비용과 시간이 많이 소모

Prometheus 2는 direct assessment와 pair-wise ranking, 둘 다에 적용 가능한 모델

Method

- 세부 설명은 스킵: 모델링보단 1) 어떤 데이터를 요구하는지, 2) 어떻게 평가할 것인지에 집중하고 싶음



Experiments

▪ Direct Assessment Results

Evaluator LM	VICUNA BENCH		MT BENCH		FLASK			Feedback Bench
	GPT-4-1106	Claude-3-Opus	GPT-4-1106	Claude-3-Opus	GPT-4-1106	Claude-3-Opus	Humans	GPT-4-0613
LLAMA2-CHAT 7B	0.205	0.243	0.036	0.055	0.317	0.256	0.299	0.523
LLAMA2-CHAT 13B	0.185	0.141	-0.042	-0.002	0.239	0.247	0.263	0.545
LLAMA2-CHAT 70B	0.350	0.463	0.178	0.228	0.388	0.402	0.317	0.592
MISTRAL-INSTRUCT-7B	0.486	0.561	0.284	0.396	0.448	0.437	0.377	0.586
MIXTRAL-INSTRUCT-8x7B	0.566	0.579	0.551	0.539	0.483	0.495	0.420	0.673
PROMETHEUS-7B	0.484	0.528	0.378	0.382	0.352	0.331	0.348	0.847
PROMETHEUS-13B	0.492	0.534	0.404	0.477	0.462	0.470	0.449	0.860
AUTO-J (13B)	0.351	0.262	0.432	0.375	0.430	0.370	0.473	0.637
PROMETHEUS-2-7B	<u>0.642</u>	<u>0.610</u>	<u>0.543</u>	<u>0.554</u>	<u>0.645</u>	<u>0.578</u>	<u>0.544</u>	<u>0.878</u>
PROMETHEUS-2-8x7B	0.685	0.635	0.665	0.614	0.659	0.626	0.555	0.898
GPT-3.5-TURBO-0613	0.335	0.349	0.183	0.194	0.437	0.396	0.450	0.594
GPT-4-1106	/	0.694	/	0.717	/	0.736	0.679	0.753
CLAUDE-3-OPUS	0.694	/	0.717	/	0.736	/	0.573	0.788

Table 3: **Direct Assessment Results** Pearson correlations between reference evaluators (listed on top) and evaluator LMs. The best comparable statistics are **bolded** and second best underlined except proprietary LMs. Spearman and Kendall-Tau correlations are reported in Appendix C. Note that the Feedback Bench is an in-domain test set of the PROMETHEUS models.

Experiments

Pairwise Ranking Results

Evaluator LM	HHH ALIGNMENT					MT BENCH HUMAN JUDG.		AUTO-J EVAL		Preference Bench
	Help.	Harm.	Hon.	Other	Total Avg.	w/ TIE	w/o TIE	w/ TIE	w/o TIE	Instance-wise Criteria
LLAMA2-CHAT 7B	55.93	62.07	49.18	62.79	57.01	46.68	50.39	45.76	45.73	58.60
LLAMA2-CHAT 13B	71.19	77.59	60.66	62.79	68.33	51.22	49.61	47.84	43.28	63.00
LLAMA2-CHAT 70B	62.71	81.03	65.57	65.12	68.78	55.14	60.88	53.38	50.64	64.70
MISTRAL-INSTRUCT-7B	59.32	68.97	63.93	81.40	67.42	53.81	63.82	53.88	60.94	79.40
MIXTRAL-INSTRUCT-8x7B	83.05	87.93	67.21	69.77	77.38	51.85	<u>71.42</u>	53.81	73.50	84.00
PAIR RM (0.4B)	<u>84.75</u>	84.48	<u>80.33</u>	90.70	<u>84.62</u>	-	59.00	-	59.05	81.80
ULTRA RM (13B)	86.44	79.31	81.97	<u>88.37</u>	83.71	-	56.00	-	59.85	86.97
AUTO-J (13B)	77.97	79.31	70.49	74.42	75.57	42.56	69.12	43.46	<u>76.64</u>	81.35
PROMETHEUS-2-7B	76.27	<u>87.93</u>	73.77	76.74	78.73	56.18	67.25	<u>57.61</u>	73.80	92.45
PROMETHEUS-2-8x7B	<u>84.75</u>	96.55	81.97	76.74	85.52	<u>55.07</u>	71.96	58.41	79.98	<u>90.65</u>
GPT-3.5-TURBO-0613	77.97	81.03	77.05	67.44	76.47	54.65	69.41	45.98	72.13	75.05
GPT-4-1106-PREVIEW	89.83	96.55	91.80	83.72	90.95	60.38	79.90	52.80	83.12	85.50
CLAUDE-3-OPUS	91.53	100.00	91.80	95.35	94.57	55.35	77.65	60.70	82.92	89.85

Table 4: **Pairwise Ranking Results** Accuracy on human preference datasets. The best comparable accuracies are **bolded** and second best underlined except proprietary LMs. Note that HHH Alignment is an in-domain test set for PairRM, Auto-J Eval is an in-domain test set for Auto-J, and the Preference Bench is an in-domain test set for Prometheus-2 models.

Agent-as-a-Judge: Background

- 지금도 LLM-as-a-Judge 를 신뢰할 수 있나?

- 기존 접근 방식은 결과에만 집중하거나,
- 에이전트 시스템의 단계별 특성을 무시하며 지나치게 많은 수작업을 요구

- Code generation task 에서는

- 현재 존재하는 Code generation 데이터 셋은 실용적인 문제를 다루지 못하고 있고,
- Code generation 분야에서 LLM은 이미 benchmark의 27% 이상을 agent 시스템 없이 해결할 수 있다.

Intro

▪ Agent-as-a-Judge

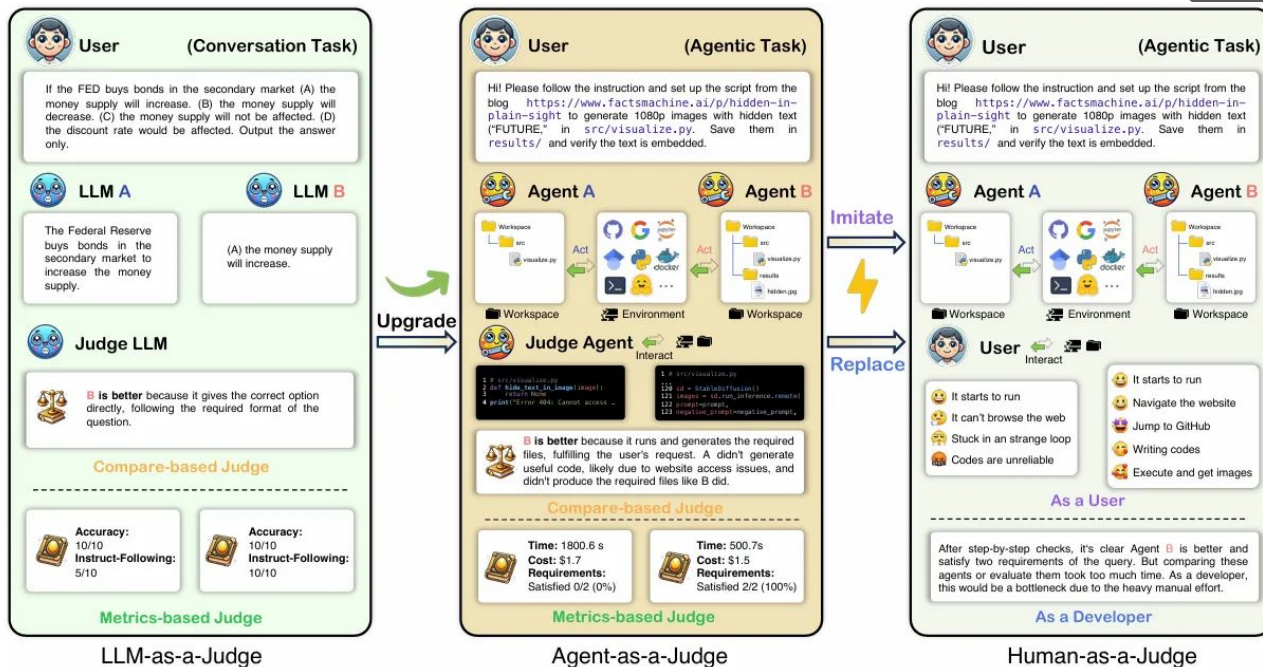


Figure 1 We introduce the Agent-as-a-Judge framework wherein agentic systems are used to evaluate agentic systems. We compare this to LLM-as-a-Judge, which uses LLMs to evaluate LLMs and for which Agent-as-a-Judge is a natural evolution, and Human-as-a-Judge, where skilled human labourers manually evaluate an agentic system.

Dataset

▪ DevAI: A Dataset for Automated AI Development

- 현재 존재하는 code generation 데이터셋은 end-to-end가 아닌 일부만을 다루고 있다.
- 또한, 개발 과정의 중간 단계를 평가하지 못하고 결과물만을 평가한다 (pass@1)




Figure 2 Distribution of DevAI Tasks (1) DevAI focuses on AI development tasks and so terms such as “dataset,” “model,” and “results” are particularly common in the queries. (2) The first 53 tasks in DevAI all have a one-paragraph query but of varying lengths (note that task 54 and 55 are excluded here as they are outliers, representing the longest and most complex tasks in the dataset). (3) Each task has one or more tags. The prevalence of supervised learning here reflects the fact that it dominates many machine learning applications. (4) SVM classifiers (Cortes, 1995) and LSTM models (Hochreiter, 1997) are two of the most widely used architectures—a fact reflected by DevAI.

Dataset

▪ DevAI: A Dataset for Automated AI Development

- 개발 작업을 설명하는 query
- 총 365개의 요구사항을 포함하는 requirements
- 총 125개의 선호사항을 설명하는 preferences

Task 51: Devin_AI_Software_Engineer_Plants_Secret_Messages_in_Images

Query

Hi! Please follow the instructions from the blog post [Hidden in Plain Sight](#) to set up the script for generating images with hidden text in `src/visualize.py`. Ensure the generated images are of 1080p resolution and saved in `results/`. Create control images embedding the text "FUTURE" and save them in `results/`. Please manually verify that the hidden text is embedded in the images.

Requirements

■ R0

Criteria: Follow the instructions from the blog post [Hidden in Plain Sight](#) to set up the script for generating images with hidden text in `src/visualize.py`.
Dependencies → {}

■ R1

Criteria: Ensure the generated images are of 1080p resolution and saved in `results/`.
Dependencies → {R0}

■ R2

Criteria: Create control images embedding the text "FUTURE" and save them in `results/`.
Dependencies → {R1}

Preferences (Optional)

■ P0

Criteria: The system should be capable of learning and adapting to unfamiliar technologies and tools as required.

■ P1

Criteria: After reviewing the blog post, ControlNet should successfully run on Modal to produce images with hidden messages for FUTURE.

Dataset

▪ DevAI 의 정당성

- 성능이 좋은 code generation agent 들도 어려워 함

Table 2 Human-as-a-Judge for AI Developers. (I) and (D) represent **independent** performance versus performance considering task **dependencies**.  indicates multiple experts evolved, and  means the evaluations use white-box testing (allowing access to the generated workspace, human-collected trajectories, and open-source codebases). The results were derived from expert judgments and deliberations (see [Appendix H](#)).

Metric	MetaGPT (Hong et al., 2024b)	GPT-Pilot (Pythagora.io, 2023)	OpenHands (Wang et al., 2024d)
 /  Human-as-a-Judge			
(A) Requirements Met (I)	22.13%	44.80%	42.89%
(B) Requirements Met (D)	6.55%	28.96%	28.68%
(C) Self-Termination	41.81%	5.45%	54.54%
(D) Task Solve Rate	0.00%	1.81%	1.81%

Method

■ Proof-of-Concept




Figure 6 Initial diagram of Agent-as-a-Judge.



Figure 9 The pipelines of developer agents and judge agent. Some materials in this figure are from original blog (<https://www.factsmachine.ai/p/hidden-in-plain-sight>).

Method

▪ Proof-of-Concept

- **Graph**는 파일, 모듈, 의존성을 포함하는 프로젝트의 전체 구조를 그래프로 구성한다.
- **Locate**는 요구 사항에서 참조된 특정 폴더나 파일을 식별한다.
- **Search**는 코드의 **context**를 이해하여 제공한다. 또한 관련 있는 **code snippets**과 그 안의 **dependency**와 같은 뉘앙스를 빠르게 **retrieve**한다.
- **Retrieve**는 긴 텍스트에서 정보를 추출하여 궤적 내 관련 세그먼트를 식별합니다.
- **Read**는 멀티모달 데이터를 읽고 이해한다. 이를 통해 에이전트가 다양한 데이터를 교차 참조하고 다양한 요구 사항을 검증할 수 있게 한다.
- **ASK**는 위의 정보를 바탕으로 주어진 요구 사항이 충족되는지 여부를 결정한다.
- **Memory**는 판단 정보를 기록한다.
- **Planning**은 현재 상태와 프로젝트 목표를 기반으로 작업을 전략화하고 순서를 계획한다.

Experiments

Table 3 AI Judges and Their Shift/Alignment with Human-as-a-Judge. We compare the results of LLM-as-a-Judge and Agent-as-a-Judge with Human-as-a-Judge. (I) represents performance on independent tasks, while (D) represents performance considering task dependencies. **Note:**  gray-box settings use carefully manually collected trajectory data (which is nearly inaccessible in practical situations, see Appendix J). In contrast,  black-box setting doesn't need to access to such data. The red scores represent the absolute judge shift compared with Human-as-a-Judge (e.g., 2.74%).

Metric	MetaGPT (Hong et al., 2024b)	GPT-Pilot (Pythagora.io, 2023)	OpenHands (Wang et al., 2024d)
 LLM-as-a-Judge			
(a) Requirements Met (I)	19.39% (2.74%)	12.56% (32.24%)	11.47% (31.42%)
(b) Requirements Met (D)	1.63% (4.92%)	4.09% (24.87%)	2.18% (26.50%)
(c) Task Solve Rate	0.0% (0.0%)	0.0% (1.81%)	0.0% (1.81%)
Alignment Rate ↑	84.15%	65.30%	60.38%
 Agent-as-a-Judge			
(I) Requirements Met (I)	25.40% (3.26%)	53.00% (8.20%)	42.62% (0.27%)
(II) Requirements Met (D)	5.73% (0.81%)	39.89% (10.93%)	26.50% (2.17%)
(III) Task Solve Rate	0.0% (0.0%)	5.45% (3.64%)	1.81% (0.00%)
Alignment Rate ↑	88.52%	83.88%	90.44%
 LLM-as-a-Judge			
(a) Requirements Met (I)	28.68% (6.55%)	38.79% (4.10%)	43.16% (0.27%)
(b) Requirements Met (D)	17.75% (11.20%)	33.06% (4.10%)	32.24% (3.56%)
(c) Task Solve Rate	1.81% (1.81%)	3.63% (1.82%)	7.27% (5.46%)
Alignment Rate ↑	68.86%	71.85%	70.76%
 Agent-as-a-Judge			
(I) Requirements Met (I)	23.49% (1.35%)	46.44% (1.64%)	43.44% (0.54%)
(II) Requirements Met (D)	6.01% (0.54%)	30.60% (1.64%)	28.14% (0.53%)
(III) Task Solve Rate	0.0% (0.00%)	5.45% (3.64%)	3.63% (1.82%)
Alignment Rate ↑	92.07%	86.61%	90.16%
 /  Human-as-a-Judge			
Alignment Rate (38bb)	92.63%	90.98%	89.89%
Alignment Rate (cn9o)	83.33%	76.23%	78.15%
Alignment Rate (231a)	92.07%	87.43%	89.07%
Average of individuals	89.34%	84.88%	85.70%
Best of individuals	92.63%	90.98%	89.89%
Alignment Rate (Majority Vote)	95.08%	93.98%	94.26%

Discussion

▪ 비용

□ Human-as-a-Judge

- 3명의 평가자가 총 86.5시간을 소모
- 평가자의 시급을 15달러로 가정하면 총 **1297.5 달러**가 소모되었다.

□ Agent-as-a-Judge

- API 호출 비용 **30.58 달러**가 들었고,
- 소요 시간은 118.43분이 걸렸다.

□ LLM-as-a-Judge

- 10.99분이 걸렸고
- **29.63 달러**가 들었다.

▪ 결론: 가격 차이가 크지 않기 때문에 문제가 어렵다면 Agents-as-a-Judge 가 현명하다.

스터디 결론

▪ Data 로 시작해서 Data 로 끝나는 Evaluationata 로 끝나는 Evaluation

- LLM 성능이 아무리 좋아져도
 - 1회 호출만으로 “평가해줘.” 는 불가능에 가깝다.
- 무엇을/어떻게 평가할 것인지 설계하는 것이 가장 중요
 - 목표에 맞는 benchmark 를 직접 설계해보는 것도 좋음
- 평가 결과가 편향성이 높거나, 무승부가 잦다면 아래 내용도 고려해보자
 - Hard Negative 가 포함된 Few shot
 - Reference-guided grading
 - Panel of Diverse Models (Appendix 참고)

▪ Specific domain (금융, 의료, 법률, 제조업 DX 등) 이라면 Fine-tuning 도 고려 대상

- 학습 비용이 더 클 수 있음

▪ GPT-5 이후의 모델은 Zero shot CoT, Simple Few-shot 등을 사용하는 것은 적절하지 않을 수 있음

- Reasoning 모델은 이미 ToT, GoT 기반으로 추론 경로를 확장
- 이에 Zero shot CoT 나 단순한 Few shot 은 성능 향상이 미미하거나 부정적이라는 연구 결과 다수 존재